

Introducción a IA

Ariel Groisman

ariel.groisman@gmail.com

www.linkedin.com/in/ariel-groisman


Junio 2020

Temas

- Aplicaciones generales
- Qué es IA? Machine Learning? Deep Learning?
- Problemas de Regresión
- Problemas de Clasificación
- Aplicaciones en audio
- Referencias

Aplicaciones generales

- SPAM Filter




Aplicaciones generales

- Motores de búsqueda




Aplicaciones generales

- Chatbots




Aplicaciones generales

- Medicina: diagnóstico por imágenes




Aplicaciones generales

- Problema del viajante (Traveling salesman problem):
 - Encontrar la ruta más corta posible que visite cada ciudad una sola vez en un mapa, regresando a la ciudad de origen.
 - Múltiples aplicaciones: la planificación, la logística, en la fabricación de circuitos electrónicos.



- Para 5 ciudades hay $(5-1)!/2=12$ rutas diferentes
- Para 10 ciudades hay $(10-1)!/2=181.440$ rutas diferentes
- Para 30 ciudades hay más de $4 \cdot 10^{30}$ rutas posibles.




Aplicaciones generales

- Finanzas



Aplicaciones generales

- Marketing Digital




Aplicaciones generales

- Detección de Fraude




Aplicaciones generales

- Abogacía




Aplicaciones generales

- Face recognition




Aplicaciones generales

- Sistemas de recomendación



Aplicaciones generales

- Autos autónomos



Aplicaciones generales

- Arte



Aplicaciones generales

- Generación de texto



Talk to Transformer

See how a modern neural network completes your text. Type a custom snippet or try one of the examples. [Learn more below.](#)

Custom prompt




Type something and a neural network will guess what comes next.


COMPLETE TEXT

Qué es IA? Machine Learning? Deep Learning?


La idea fundamental en que se basa la Inteligencia Artificial es en conseguir que una computadora resuelva un problema complejo como lo haría un humano.



Evolución




Ley de Moore




Aproximadamente cada dos años se duplica el número de transistores en un microprocesador.

Programación Tradicional vs. Machine Learning





Arthur Samuel (1959): “el campo de estudio que da a las computadoras la capacidad de aprender sin estar programado explícitamente.”


Qué es Deep Learning?




Qué es una Red Neuronal?




Qué es una Red Neuronal?





Ejemplo de una Red Neuronal




Qué es Deep Learning?



Machine Learning vs. Deep Learning




Machine Learning: Supervisado vs. No Supervisado




Aprendizaje Supervisado

Classification



Queremos Predecir
Variable Cualitativa

Regression



Queremos Predecir
Variable Cuantitativa

Ejemplo de Regresión Lineal: Tips Dataset

	total_bill	tip	sex	smoker	day	time	size
0	16.99	1.01	Female	No	Sun	Dinner	2
1	10.34	1.66	Male	No	Sun	Dinner	3
2	21.01	3.50	Male	No	Sun	Dinner	3
3	23.68	3.31	Male	No	Sun	Dinner	2
4	24.59	3.61	Female	No	Sun	Dinner	4
...	...	...	...	...	...	...	...
239	29.03	5.92	Male	No	Sat	Dinner	3
240	27.18	2.00	Female	Yes	Sat	Dinner	2
241	22.67	2.00	Male	Yes	Sat	Dinner	2
242	17.82	1.75	Male	No	Sat	Dinner	2
243	18.78	3.00	Female	No	Thur	Dinner	2


X


y


X


Ejemplo de Regresión Lineal: Tips Dataset

	total_bill	tip
0	16.99	1.01
1	10.34	1.66
2	21.01	3.50
3	23.68	3.31
4	24.59	3.61
...	...	...
239	29.03	5.92
240	27.18	2.00
241	22.67	2.00
242	17.82	1.75
243	18.78	3.00

**x**

**y**


Train-Test Split




Ejemplo de Regresión Lineal: Tips Dataset

	total_bill	tip	
0	16.99	1.01	Train: 80%
1	10.34	1.66	
2	21.01	3.50	
3	23.68	3.31	
4	24.59	3.61	
...	...	...	
239	29.03	5.92	Test: 20%
240	27.18	2.00	
241	22.67	2.00	
242	17.82	1.75	
243	18.78	3.00	

 **x**  **y**



Ejemplo de Regresión Lineal: Tips Dataset



β_0 y β_1 son los coeficientes desconocidos que vamos a estimar o ajustar en base a los datos de entrenamiento. Una vez estimados, los podemos usar para predecir:

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 \cdot x$$

Diagram illustrating the components of the linear regression equation $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 \cdot x$:

- $\hat{y}$: Valor predicho para Y cuando $X=x$
- $\hat{\beta}_0$: Estimación de β_0
- $\hat{\beta}_1$: Estimación de β_1
- x : Nueva instancia

Estimación de los coeficientes

- Definición: Residuo o error de predicción

$$e_i = y_i - \hat{y}_i$$


- Residual sum of squares:

$$\text{RSS} = e_1^2 + e_2^2 + \dots + e_n^2,$$

$$\text{RSS} = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 \cdot x_i)^2$$


- Buscamos $\hat{\beta}_0$ y $\hat{\beta}_1$ que minimizan RSS.

GRADIENTE DESCENDENTE



Gradiente Descendente

- Es un algoritmo para encontrar el mínimo de una función de manera iterativa.
- Sea $J(\mathbf{w}, \mathbf{b})$ una función
- Queremos $\mathbf{w}, \mathbf{b}$ tal que J sea mínima: $\min_{\mathbf{w}, \mathbf{b}} J(\mathbf{w}, \mathbf{b})$




Esquema general de GD:

- Inicializar $\mathbf{w}, \mathbf{b}$ con algún valor cualquiera ($\mathbf{w}=0, \mathbf{b}=0$)
- Modificar $\mathbf{w}, \mathbf{b}$ intentando minimizar J hasta que, con suerte, encontremos un mínimo


Sirve para minimizar cualquier función en general: $J(\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_n)$

Gradiente Descendente sobre una variable




Aprendizaje Supervisado

Classification




Queremos Predecir
Variable Cualitativa

Regression



Queremos Predecir
Variable Cuantitativa

Ejemplo de Clasificación: Iris Dataset



Iris Versicolor



Iris Setosa



Iris Virginica

Ejemplo de Clasificación: Iris Dataset

	sepal_length	sepal_width	petal_length	petal_width	species
0	5.1	3.5	1.4	0.2	setosa
1	4.9	3.0	1.4	0.2	setosa
2	4.7	3.2	1.3	0.2	setosa
3	4.6	3.1	1.5	0.2	setosa
4	5.0	3.6	1.4	0.2	setosa

Ejemplo de Clasificación: Iris Dataset

	sepal_length	sepal_width	petal_length	petal_width	species
0	5.1	3.5	1.4	0.2	setosa
1	4.9	3.0	1.4	0.2	setosa
2	4.7	3.2	1.3	0.2	setosa
3	4.6	3.1	1.5	0.2	setosa
4	5.0	3.6	1.4	0.2	setosa




X




y

Ejemplo de Clasificación: Iris Dataset




Cuál es el mejor modelo?


Underfit



Good fit



Overfit



Métricas para evaluar el modelo de clasificación

COVID 19 = 1



Healthy = 0



Actual

Predict

	Diagnosed COVID 19 (1)	Diagnosed Healthy (0)
COVID 19 (1)	✓ TP 	✗ FP
Healthy (0)	✗ FN 	✓ TN

Métricas para evaluar el modelo de clasificación

- **Falsos Positivos (FP):** es una clase negativa que fue clasificada como positivo. Ejemplo: al individuo se lo clasificó como enfermo, pero estaba sano.
- **Falsos Negativos (FN):** es una clase positiva que fue clasificada como negativa. Ejemplo: al individuo se lo clasificó como sano, pero estaba enfermo.
- **Verdaderos Positivos (TP):** es una clase positiva clasificada correctamente.
- **Verdaderos Negativos (TN):** es una clase negativa clasificada correctamente.

COVID 19 = 1 

Healthy = 0 



		Actual	
		Diagnosed COVID 19 (1)	Diagnosed Healthy (0)
Predict	COVID 19 (1)	 TP 	 FP 
	Healthy (0)	 FN 	 TN 

Métricas para evaluar el modelo de clasificación

COVID 19 = 1 

Healthy = 0 



Cost of FN > Cost of FP

Actual


Predict

	Diagnosed COVID 19 (1)	Diagnosed Healthy (0)
COVID 19 (1)	✓ TP 	✗ FP 
Healthy (0)	✗ FN 	✓ TN 


Healthy predicted as sick

Sick predicted as healthy

Métricas para evaluar el modelo de clasificación



 Accuracy = $\frac{TP + TN}{TP + TN + FP + FN}$


 Specificity = $\frac{TN}{TN + FP}$

 Precision = $\frac{TP}{TP + FP}$

 Recall = $\frac{TP}{TP + FN}$

Aplicaciones en audio

- Clasificación de fuentes sonoras




Aplicaciones en audio

- Speech recognition (Siri, Alexa)




Aplicaciones en audio

- Reconocimiento de emociones en la voz



Aplicaciones en audio

- Reconocimiento de canciones (Shazam): acoustic fingerprint



Aplicaciones en audio

- Síntesis de audio

Preprint


File available

GACELA – A generative adversarial context encoder for long audio inpainting

May 2020



Project: [MERLIN](#)

Andrés Marafioti · Piotr Majdak · Nicki Holighaus · Nathanaël Perraudin



Aplicaciones en audio

- Reducción de ruido en comunicaciones



Referencias

- Cursos Online
 - [Python for Data Science and Machine Learning Bootcamp, Jose Portilla \(Udemy\)](#)
 - [Curso de Machine Learning, Andrew Ng \(Coursera\)](#)
 - [Deep Learning Specialization, Andrew Ng \(Coursera\)](#)
- Libros
 - Python Data Science Handbook: Essential Tools for Working with Data. Jake VanderPlas. O'Reilly Media, Inc. (2016)
 - Introduction to Machine Learning with Python. Andreas C. Müller, Sarah Guido. O'Reilly Media, Inc. (2016)
 - Hands-On Machine Learning with Scikit-Learn and TensorFlow. Aurélien Géron. O'Reilly Media, Inc. (2019)
- Webs
 - [Medium](#)
 - [Kaggle](#)